

WORKSHOP

Análise de expressão diferencial em RNA-seq

Do dado público ao gene candidato — em R (RStudio) e em Python (Colab)

MMRF-CoMMpass · NCI Genomic Data Commons · DESeq2 + PyDESeq2

Tiago Fernando Chaves · Biólogo, PhD em Biologia Celular e do Desenvolvimento (UFSC)



fapesc
Fundação de Amparo à
Pesquisa e Inovação do
Estado de Santa Catarina

O que você vai fazer hoje

Em algumas horas, do dado bruto público até uma lista de genes com significado biológico

1

pergunta biológica,
formulada com
honestidade

60

amostras reais de
pacientes
com mieloma múltiplo

2

implementações
independentes
do mesmo método

0

linhas de código
que você vai escrever

O objetivo não é você sair sabendo programar.

É você sair sabendo ler uma análise de expressão diferencial — a sua ou a de outra pessoa — e reconhecer quando ela está errada. Rodar é a parte fácil. Confiar no resultado é a parte difícil.

A mesma análise, duas vezes

Dia 1 em R. Dia 2 em Python. Mesmo dado, mesmo contraste, mesmos limiares.

1 DESeq2 — no seu RStudio

A implementação de referência: o artigo de 2014* que define o método e praticamente toda a literatura usam esta versão.

Scripts que rodam na sua máquina. O painel Environment mostra os objetos; View() abre a tabela de resultados com ordenação.

2 PyDESeq2 — no Colab

Mesmo método estatístico, código escrito do zero por outro grupo**.

O segundo passe custa menos da metade do tempo: a lógica já é conhecida, só a sintaxe muda.

E aí vem a pergunta que fecha o workshop: as duas chegam ao mesmo resultado?

* Love MI, Huber W, Anders S. **Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2.** *Genome Biology* 2014;15(12):550. doi:10.1186/s13059-014-0550-8

** Muzellec B, Teleńczuk M, Cabeli V, Andreux M. *PyDESeq2: a python package for bulk RNA-seq differential expression analysis.* **Bioinformatics** 2023;39(9):btad547. doi:10.1093/bioinformatics/btad547

Roteiro

Dois encontros de quatro horas

DIA 1 — R e DESeq2

M0	RStudio, atalhos, e o que é uma contagem	20 min
M1	Onde mora o dado e o desenho do contraste	30 min
M2	Da contagem à matriz	25 min
M3	QC e exploração antes do teste	40 min
M4	DESeq(): as quatro etapas	55 min
M5	Visualização honesta	35 min
M6	Da lista ao significado	25 min
M7/8	Reprodutibilidade e controle positivo	20 min

DIA 2 — Python e concordância

—	Recapitulação do dia anterior	15 min
M0-2	O mesmo caminho em Python	40 min
M3-4	PyDESeq2: onde difere, onde é igual	50 min
M5	Os mesmos gráficos, com matplotlib	25 min
M9	Concordância R × Python	50 min
M6	Enriquecimento e universo de fundo	30 min
M7	Limitações e seção de métodos	25 min
—	Encerramento	10 min




Por que RNA-seq

O que exatamente é uma contagem — e por que ela é um número ruidoso



O caminho do dado

O workshop começa na última caixa. Tudo antes dela já foi feito pelo consórcio.



Nosso ponto de partida é uma tabela: linhas = genes, colunas = amostras, células = números inteiros. O próximo slide detalha o que ficou para trás.

gene_id	AMOSTRA_1	AMOSTRA_2
AMOSTRA_3		
ENSG00000136997	4821	1204
7733		
ENSG00000110092	318	942
205		

0

O que já foi feito antes da contagem

Quatro etapas que o consórcio rodou por você — e que valem uma tarde de laboratório

1

FASTQ

Texto puro: quatro linhas por read. A quarta codifica a probabilidade de erro de cada base.

2

QC e trimming

FastQC mede, não corrige. Trimming agressivo por qualidade piora a expressão diferencial — o GDC não faz nenhum.

3

Alinhamento

STAR two-pass contra o hg38. Precisa cruzar íntrons — é isso que separa um alinhador de RNA de um de DNA.

4

Contagem

STAR --quantMode GeneCounts sobre a anotação GENCODE v36. Daí as 60.665 linhas da sua matriz.

Módulo 0.5, opcional: você roda esse caminho inteiro no Colab, com quatro amostras de levedura, em dez minutos.

0

Uma contagem depende de três coisas

Só uma delas é biologia. As outras duas são técnicas — e é por isso que existe estatística aqui.

1 Expressão real

Quantas moléculas daquele transcrito existiam na célula.

É o que você quer medir.

2 Tamanho da biblioteca

Uma amostra sequenciada com 40 M de reads dá o dobro de contagens de uma com 20 M, para a mesma expressão.

Resolve-se com normalização.

3 Comprimento do gene

Gene longo captura mais reads que gene curto igualmente expresso.

Irrelevante quando se compara o MESMO gene entre amostras.

E há um quarto fator, que não some nunca: acaso. Sequenciamento é amostragem — um gene com 10 reads e outro com 10.000 não merecem a mesma confiança.



Por que TPM e FPKM não entram no DESeq2

O arquivo do GDC traz essas colunas. Não as use aqui.

O que o modelo precisa

O DESeq2 assume que a contagem segue uma distribuição binomial negativa. Ele usa o número inteiro de reads para estimar quanta variância é esperada naquele nível de expressão.

É assim que ele sabe que +2× num gene de 10 reads é ruído, e +2× num gene de 10.000 reads não é.

O que se perde com TPM/FPKM

São valores já normalizados e contínuos. A informação sobre quantos reads sustentavam aquele número desaparece.

Sem ela, o modelo não distingue gene de baixa expressão de gene de alta expressão — e passa a chamar ruído de resultado.

Regra prática: para expressão diferencial, use contagem bruta. TPM serve para olhar um gene, comparar tecidos, fazer heatmap descritivo.

1

Onde mora o dado

GDC, metadados — e a conversa mais importante do workshop: o desenho do contraste

1

NCI Genomic Data Commons

O repositório público de dados genômicos de câncer do Instituto Nacional do Câncer dos EUA

- Dados de milhares de pacientes, processados por um pipeline único e padronizado
- É essa padronização que torna as amostras comparáveis entre si
- Parte é de acesso aberto; parte exige autorização via dbGaP
- Tem interface web para explorar e uma API para buscar de forma programática

Nossa consulta, em português:

```
projeto    = MMRF-COMMPASS
tipo       = Gene Expression
Quantification
workflow   = STAR - Counts
acesso     = open

→ devolve: file_id + sample_type
           de cada arquivo
```

O projeto MMRF-CoMMpass acompanhou mais de mil pacientes com mieloma múltiplo ao longo de anos, coletando amostra no diagnóstico e a cada progressão da doença.

A primeira pergunta que você deveria fazer

Onde está o tecido normal?

Não existe.

As grandes coortes públicas de mieloma múltiplo são inteiramente tumorais. Plasmócito normal de medula é raro — cerca de 1 em cada 10 mil células nucleadas —, difícil de purificar em quantidade, e coletá-lo exige aspirado de medula de voluntário saudável.

Isso não é um defeito do dado. É uma característica da doença — e muda a pergunta que podemos fazer.

1

Então o que comparamos?

Quatro caminhos possíveis. Só um serve para hoje.

Diagnóstico × recidiva	MMRF-CoMMpass, RNA-seq, acesso aberto, n grande	ESCOLHIDO
Alto × baixo risco (ISS)	Mesmo dado, precisa cruzar com o clínico	desafio final
Tumor × plasmócito normal	Só existe em microarray antigo — não é contagem	inviável
Reaproveitar o TCGA-CHOL	Tem normal, mas não é mieloma	só gabarito

Vantagem escondida do escolhido: sai de graça do campo sample_type dos metadados. Nenhum dado clínico extra necessário.

1 Armadilha: o mesmo paciente duas vezes

O CoMMpass é longitudinal — e isso quebra uma premissa do modelo



Amostras do mesmo paciente não são independentes

O estudo coletou amostra no diagnóstico e de novo a cada progressão. Um mesmo paciente pode aparecer nos dois grupos. Tratar essas amostras como independentes infla a confiança do teste — o modelo acha que tem mais informação do que realmente tem.



Manter uma amostra por paciente

Simples, defensável, perde poder estatístico.

É o que o notebook faz hoje.



Modelar o pareamento

Desenho ~ paciente + condicao. Aproveita o pareamento e ganha poder.

Mais correto, mais complexo — fica de menção.

1 O que este contraste NÃO permite afirmar

Escreva isso no seu resultado. Antes de ver o resultado.

1 Nada sobre mieloma × tecido normal

Não há plasmócito saudável no dado. Qualquer frase do tipo 'gene X está aumentado no mieloma' é injustificada aqui.

2 O tratamento é um confundidor

Entre o diagnóstico e a recidiva o paciente recebeu terapia. Progressão da doença e resposta ao tratamento estão misturadas e não são separáveis neste desenho.

3 Pureza da amostra varia

A fração de plasmócitos tumorais na seleção CD138+ difere entre pacientes. Diferença de expressão pode ser diferença de composição celular.

2

Da contagem à matriz

Abrindo o arquivo bruto — a etapa que quase ninguém olha

Anatomia de um arquivo STAR-Counts

Muita gente analisa RNA-seq a vida inteira sem nunca ter aberto um destes

```
# gene-model: GENCODE v36          ← comentário: quebra o read_csv ingênuo
gene_id      gene_name  gene_type  unstranded  stranded_first ...
N_unmapped                                1339807      1339807
N_multimapping                        4471203      4471203
N_noFeature                          2288119      27180944
N_ambiguous                          4664374      661104
ENSG000000000003.15  TSPAN6    protein_coding      217        104
ENSG000000000005.6   TNMD      protein_coding       0         0
```

Linha 1 é comentário

Diz qual anotação foi usada. Precisa ser pulada na leitura.

Linhas N_* não são genes

São o resumo do alinhamento. Somá-las junto com os genes infla o tamanho da biblioteca.

ID com versão

ENSG000000000003.15 — o .15 é a versão da anotação, não parte do identificador.

2

Qual coluna de contagem usar?

unstranded, stranded_first ou stranded_second — três respostas para a mesma pergunta

Como saber qual é a certa

Depende do kit usado na preparação da biblioteca. A regra prática do próprio GDC: compare N_ambiguous entre as três colunas. Se uma das colunas stranded tem N_ambiguous muito menor que as outras, a biblioteca é stranded — e é aquela que você deve usar.

A regra inegociável

Dados de strandness diferente não se comparam diretamente.

Se metade da sua coorte é stranded e metade não é, você não tem uma coorte — tem duas, e a diferença entre elas vai aparecer como se fosse biologia.

Hoje vamos usar a coluna unstranded. Não porque seja sempre certa — porque é consistente em todas as amostras deste conjunto.

2

Por que 60 mil linhas?

O genoma humano tem cerca de 20 mil genes codificantes. A matriz tem o triplo.

~20 mil

genes codificantes de proteína
— os que você provavelmente
estava esperando

~40 mil

pseudogenes, lncRNAs, miRNAs,
transcritos processados
e outros não codificantes

~20 mil

o que sobra depois do filtro
de expressão do Módulo 3

A coluna `gene_type` diz qual é qual. A maior parte dos não codificantes terá contagem zero ou quase — e vai cair no filtro. Isso não é desperdício: é o filtro fazendo o trabalho dele, e reduzindo o peso da correção para testes múltiplos.



3

Olhe o dado antes de testar o dado

Controle de qualidade e exploração — a regra mais importante do workshop

3

A regra

PCA antes do DESeq2. Sempre.

Um outlier ou um efeito de lote encontrado aqui vale mais do que qualquer refinamento estatístico depois. Nenhum modelo conserta um dado que você não olhou.

1

Tamanho de biblioteca

Variação de até $\sim 3\times$ é confortável. Muito acima, desconfie.

2

Filtro de genes

Fora os genes sem expressão — antes de qualquer teste.

3

PCA e clustering

As amostras se agrupam por condição? Por sexo? Por nada?

3

Filtro de genes: dois critérios

A primeira decisão real que você toma na análise

A — soma total ≥ 10

Simples e comum.

Problema: um gene com 10 reads numa única amostra, e zero em todas as outras, passa no filtro.

Esse gene não tem informação sobre grupo nenhum. Ele só ocupa espaço e aumenta o peso da correção múltipla.

B — ≥ 10 contagens em $\geq n$ amostras

Onde n é o tamanho do menor grupo.

Exige presença consistente, não um pico isolado. É o critério do `filterByExpr`, do pacote `edgeR`.

É o que vamos usar. Você vai ver a diferença no número de genes que sobram.

Não existe filtro universalmente certo. Existe filtro declarado — com o número de genes antes e depois escrito no método.

Por que VST e não $\log_2(x+1)$

Contagem bruta tem um problema: a variância depende da média

O problema

Gene muito expresso varia muito em valor absoluto; gene pouco expresso varia pouco. Não porque um seja mais regulado que o outro — é aritmética da amostragem.

Resultado: PCA e heatmap feitos sobre o dado cru são dominados pelos genes mais expressos, que raramente são os interessantes.

A solução

A VST — variance stabilizing transformation — é calculada a partir da relação média-variância do próprio dado.

Depois dela, um gene de alta e um de baixa expressão contribuem de forma comparável para a distância entre amostras. É isso que torna o PCA legível.

VST e rlog para exploração e gráficos. • Contagem bruta para o teste estatístico.

Prepare-se para isto

Seu PCA provavelmente não vai separar os grupos.

Por quê

Mieloma tem subtipos citogenéticos muito distintos — t(4;14), t(11;14), hiperdiploidia. A variação entre pacientes é maior que a variação entre diagnóstico e recidiva. O PC1 quase sempre capta o subtipo, não o momento da doença.

O que isso significa — e o que não significa

PCA que não separa NÃO quer dizer ausência de genes diferenciais. Quer dizer que o efeito é menor que a variação entre indivíduos. O modelo ainda pode encontrá-lo, porque testa gene a gene em vez de olhar a variância global.

4

O que o DESeq2 faz de verdade

Quatro etapas, em português, sem uma única fórmula

4

Quatro etapas

Tudo o que acontece quando você chama `dds.deseq2()`

1

Normalizar

Mediana de razões — corrige diferença de profundidade sem deixar poucos genes dominarem

2

Estimar dispersão

Genes de expressão parecida emprestam informação uns aos outros

3

Testar

Teste de Wald, gene a gene, sobre o log2 fold change

4

Corrigir

Benjamini-Hochberg + filtragem independente

As etapas 1 e 2 são o que separa o DESeq2 de um teste t. É onde mora quase todo o valor do método.

4

Etapa 1 — mediana de razões

Não é dividir pelo total de reads. E em mieloma isso importa muito.

Como funciona

Para cada gene, calcula-se a razão entre a contagem da amostra e a média geométrica daquele gene em todas as amostras.

O fator de tamanho da amostra é a MEDIANA dessas razões — o comportamento típico do gene mediano, não a soma.

Por que a mediana salva o mieloma

Plasmócito é uma fábrica de anticorpo. IGHG1, IGKC, IGLC1 podem sozinhos responder por uma fatia enorme da biblioteca — e a fatia varia entre pacientes conforme o isotipo do mieloma.

Com normalização por soma total, esses poucos genes sequestrariam a escala de todas as amostras. A mediana é imune a eles.

É o exemplo mais bonito de por que a escolha do método estatístico depende da biologia do tecido.

4

Imunoglobulina: filtrar antes, não depois

A mediana de razões salva a normalização. Ela não salva o teste.

Se você filtrar só na hora do gráfico

Os segmentos V(D)J — IGKV, IGHV, IGLV — entram no ajuste do modelo e no cálculo do FDR.

Cada paciente tem um rearranjo clone-específico diferente. Sorteie outro conjunto de amostras e o topo da lista muda de nome.

Se você filtrar antes de ajustar

REMOVED_IG = True, idêntico em R e em Python, aplicado à matriz antes do DESeq2.

O que sobra é biologia compartilhada entre pacientes, que é a única coisa que o contraste pode medir.

O rearranjo V(D)J não é biologia da recidiva. É identidade do paciente.

O encolhimento do fold change

Um gene com 12 reads pode ter log2FC de +8. Isso é ruído, não biologia.

Sem shrinkage

O topo da sua lista, quando ordenada por fold change, enche de genes de baixíssima expressão com efeitos gigantes e sem sustentação.

O volcano ganha caudas laterais espetaculares e irrelevantes.

Com `lfc_shrink()`

O efeito é encolhido na proporção da incerteza da estimativa. Gene bem medido quase não muda; gene mal medido é puxado para perto de zero.

A ordenação passa a refletir evidência, não sorte.

Teste com o fold change bruto. · Ranqueie e plote com o fold change encolhido.

4

FGFR3: o encolhimento em um caso real

O mesmo gene, o mesmo teste, duas estimativas — e só uma delas é honesta

log2FC bruto: -3,281

Pareceria um achado e tanto: FGFR3 é o alvo da t(4;14), translocação de prognóstico ruim.

Mediana das contagens: 51 e 40. Máximo: 516.200.

log2FC encolhido: -0,041

O apeglm mede a incerteza e puxa o efeito para perto de zero: ele se apoia em pouquíssimas amostras.

padj final: 1,00. O gene não sai da tabela — sai do topo.

Um efeito enorme sustentado por pouquíssimas amostras não é um efeito.

Onde entra o limiar de fold change

Filtrar depois do teste e testar com limiar não são a mesma coisa

O jeito comum

Testa a hipótese 'o efeito é zero'. Depois filtra a tabela por $|\log_2FC| \geq 1$.

O FDR que você reporta foi calculado para OUTRA pergunta — a de que o efeito é exatamente zero. Depois do filtro, ele não descreve mais o conjunto que você está mostrando.

O jeito correto

Declara o limiar dentro do teste: a hipótese nula passa a ser 'o efeito é menor ou igual a 1'.

O FDR então controla exatamente a pergunta que você quer responder — quantos dos genes que chamei de 'mudaram pelo menos 2x' não mudaram tanto assim.

No notebook isso é uma chave: `TESTAR_LIMIAR_NO_MODELO`. Ligue e desligue, e compare o número de genes.

4

padj = NA não é erro

É decisão do algoritmo, e ela tem motivo

1

Filtragem independente

Genes de expressão muito baixa não teriam poder para nada. Removê-los antes da correção múltipla aumenta o número de descobertas reais entre os que sobram.

2

Distância de Cook

Uma amostra com valor extremo pode carregar sozinha o resultado de um gene. O algoritmo detecta e marca esse gene, em vez de reportar um achado que depende de um ponto.

Quando você reportar 'X genes testados', o número certo é o de genes com padj não nulo — não o número de linhas da matriz.

4

O teste de sanidade mais útil que existe

Que fração do transcriptoma saiu significativa?

< 5%

plausível para um contraste
sutil como diagnóstico × recidiva

5–25%

possível, dependendo
do tamanho do efeito

> 25%

bandeira vermelha —
pare e investigue

!

Quando um quarto do transcriptoma é significativo, geralmente não é regulação gênica

É diferença de tecido ou de composição celular. No pipeline original de colangiocarcinoma, tumor × ducto biliar normal deu 10.774 DEGs em 38.846 genes — 28%. É um resultado real, mas o que ele mede sobretudo é que fígado tumoral não é ducto biliar. Não é uma assinatura tumoral fina.



5-9

Mão na massa

Daqui em diante os slides ficam para trás e o notebook assume

5

Quatro gráficos, quatro funções

E um deles mente com frequência

MA plot

Expressão média $\times$ fold change.
O mais informativo e o menos usado: mostra na hora se a normalização funcionou.

Volcano

Fold change $\times$ significância.
Bom para comunicar, fraco para diagnosticar. Desconfie sempre das bordas.

Heatmap

Bonito, e circular quando os genes são escolhidos pelo padj.
Veja o alerta abaixo.

Contagem de um gene

Boxplot por grupo. É onde a mentira morre: mostra se o efeito vem de duas amostras extremas.



O heatmap dos top-N genes por padj separa os grupos por construção

Você selecionou os genes PORQUE eles separam os grupos, e depois mostrou que eles separam os grupos. Não é evidência de nada. Se quiser um heatmap que signifique algo: selecione genes por variância, independente do contraste, ou use uma assinatura definida a priori.

Da lista de genes ao significado

ORA e GSEA respondem a perguntas diferentes

ORA — sobre-representação

Pega a sua lista de DEGs e pergunta se alguma via aparece mais do que o acaso explicaria.

Depende de um limiar. Bom quando o efeito é forte e concentrado.

GSEA — conjunto ranqueado

Usa o transcriptoma inteiro, ordenado, sem limiar nenhum.

Mais robusto quando o efeito é sutil e distribuído — exatamente o caso de diagnóstico × recidiva.



Duas maneiras de inflar enriquecimento sem perceber

Universo de fundo errado: testar contra 'todos os genes humanos' quando você só analisou 20 mil genes filtrados infla tudo — o fundo correto são os genes que entraram no teste. E termos genéricos: quase toda lista grande de DEGs em câncer enriquece 'ciclo celular'. Conjuntos com mais de 500 genes enriquecem por inércia. Olhe o fold enrichment e o tamanho do conjunto, não só o p-valor.

A seção de métodos

Escrita enquanto você analisa, não depois que o revisor pede

O mínimo para ser reprodutível

- Fonte, release e data de acesso — o GDC reprocessa; "baixado do GDC" não identifica nada
- Critérios de inclusão e o n final por grupo
- Filtro de genes, com o número antes e depois
- Posição de cada filtro: antes do modelo ou só no gráfico
- Modelo, contraste e limiares, pré-especificados
- Versões de tudo
- Seleção de amostras por arquivo, não por semente
- Covariáveis inferidas, e como foram validadas

As limitações deste desenho

- Sem plasmócito normal — nada a dizer sobre mieloma × tecido saudável
- Tratamento entre os dois momentos: confundidor não controlado
- Pureza variável da amostra CD138+
- Sem correção de lote nem de covariáveis clínicas
- Sem coorte de validação independente
- Subamostragem didática de uma coorte maior

8

Desafio final: o controle positivo

Existe um teste que valida seu pipeline inteiro em dois minutos

Troque o contraste por sexo. Os genes do topo TÊM que ser XIST e os genes ligados ao Y — mesmo que o sexo não venha nos metadados.

O que deve aparecer

XIST com fold change negativo — alto em mulheres, praticamente ausente em homens.

RPS4Y1, DDX3Y, UTY, KDM5D e EIF1AY com fold change positivo, com padj minúsculo e no topo absoluto da lista.

Se não aparecer

Seu pipeline está errado em algum lugar: rótulos trocados, amostras desalinhadas, contraste invertido.

E é infinitamente melhor descobrir isso agora do que depois de submeter o artigo.

Quando o metadado simplesmente não existe

O controle positivo do slide anterior precisa do sexo. E o sexo não vem no dado aberto.

O que a camada aberta não entrega

demographic.gender é restrito no MMRF-CoMMpass. A API responde, o campo vem vazio.

Nível de acesso a metadado é uma restrição de reprodutibilidade tão real quanto uma versão de pacote.

O que o próprio dado entrega

Votação sobre a expressão de RPS4Y1, DDX3Y, UTY, KDM5D e EIF1AY: presentes em homens, ausentes em mulheres.

O rótulo passa a vir da matriz, não do formulário.

XIST valida a inferência: $\log_2FC = -9,08$, $p_{adj} = 1,13e-34$ — e ele não votou.

Concordância R × Python

O módulo que justifica ter feito a análise duas vezes

1 Os fold changes concordam?

Correlação entre as duas estimativas de fold change, gene a gene.

Esperado: altíssima.

2 As listas coincidem?

Índice de Jaccard entre os conjuntos de DEGs.

É o que importa: você reporta a lista, não a correlação.

3 Onde discordam?

Os três discordantes têm padj entre 0,03 e 0,10 — colados no limiar. E não são de baixa expressão: baseMean mediano de 1.645.

Se um achado depende de qual implementação você usou,
ele não é um achado firme — é um gene na fronteira do limiar.

9

O que a concordância deu

Mesmas amostras, mesmo contraste, mesmos limiares — duas implementações independentes

1

Pearson 0,9996

Correlação entre os fold changes, nos 19.283 genes testados. Os dois modelos chegaram às mesmas estimativas de efeito.

2

$\Delta \log_2FC$ 0,00025

Diferença absoluta mediana no fold change. Praticamente zero: o desacordo não está na estimativa do efeito.

3

DEGs 4 × 1

Quatro no R, um no Python. O único em comum é CXCL9; CD4, IFI27 e HLA-DQA2 ficam de fora no Python.

4

Jaccard 0,250

Sobreposição das listas — e é este o número que se reporta, não a correlação.

Fold change idêntico e listas diferentes. A explicação está no próximo slide.

Por que as listas divergem

O padj do PyDESeq2 é praticamente o dobro do padj do DESeq2 — em todos os genes comparáveis

1

Razão 1,9983

padj do Python dividido pelo padj do R. Mediana sobre os 46 genes em que os dois lados deram um p informativo.

2

Desvio 0,0006

Desvio padrão dessa razão. Ruído de convergência produziria dispersão; isto é uma constante.

3

Faixa 1,997 – 2,000

Do menor ao maior valor observado. Nenhum gene escapa do fator 2.

4

n 46 de 19.283

Com o limiar dentro do teste, os outros 19.237 ficam com padj = 1 nos dois lados — e $1 \div 1$ não informa nada.

Convenção diferente no p-valor sob H_0 composta, não bug. Qual das duas está certa, o dado não diz — só o código-fonte.

Semente igual não é sorteio igual

O bug que produziu Pearson 0,376 — e que não deu erro em lugar nenhum

O que parecia óbvio

`set.seed(42)` no R e `random_state=42` no pandas. Mesmo número, logo mesma amostragem.

Errado. São geradores diferentes, com algoritmos de embaralhamento diferentes. Os dois pipelines analisaram pacientes diferentes.

O que resolve

O R exporta `amostras_R.csv` com `file_id`, `case_id` e `condition`. O Python lê esse arquivo em vez de sortear.

A identidade das amostras deixa de ser uma coincidência e passa a ser um artefato versionado.

Paridade entre linguagens se verifica. Nunca se assume.

10

Reprodutibilidade

O que quase quebrou este pipeline — e por que nada disso gerou uma mensagem de erro

Nenhuma delas gerou um erro.

Todas as três produziram um resultado plausível, formatado, pronto para colar num artigo. Foram encontradas por controle positivo e por comparação cruzada — nunca pelo interpretador.

1

Metadado ausente

O campo veio vazio e o código seguiu. Resolvido inferindo do próprio dado, com XIST como testemunha.

2

Semente sem paridade

Dois conjuntos de pacientes diferentes, dois resultados corretos, uma comparação sem sentido.

3

Filtro na posição errada

Imunoglobulina removida do gráfico mas não do modelo. FDR calculado sobre genes que você já sabia que não interessavam.

O que levar daqui

1

O desenho do contraste decide tudo

Nenhuma sofisticação estatística conserta uma comparação que responde à pergunta errada.

2

Olhe o dado antes de testar o dado

Tamanho de biblioteca e PCA primeiro. Sempre.

3

Desconfie de listas enormes de DEGs

Muito significativo geralmente significa diferença de tecido ou de composição celular.

4

Tenha um controle positivo

Custa dois minutos e valida o pipeline inteiro de ponta a ponta.

5

Escreva o que fez enquanto faz

Release, versões, semente, limiares — definidos antes de ver o resultado.

6

Um achado que depende da ferramenta não é um achado

Os genes que importam sobrevivem às duas análises, com folga.

Para continuar

Tudo aberto, tudo gratuito

Ferramentas

RStudio Desktop
posit.co/download/rstudio-desktop

Posit Cloud — RStudio no navegador
posit.cloud

Google Colab — Python

ShinyGO — enriquecimento
bioinformatics.sdstate.edu/go

Dados

NCI Genomic Data Commons
portal.gdc.cancer.gov

MMRF CoMMpass
portal.gdc.cancer.gov/projects/MMRF-COMMPASS

Gene Expression Omnibus (GEO)

Leitura

Conesa et al. (2016)
A survey of best practices for RNA-seq data analysis. Genome Biology

Love, Huber & Anders (2014)
DESeq2. Genome Biology

Stark et al. (2019)
RNA sequencing: the teenage years. Nat Rev Genet

O notebook fica com vocês. Rode de novo com os seus dados — a estrutura é a mesma.